

Problem Statement

Sebagai lembaga pengatur utama, Bank Sentral Taiwan punya tanggung jawab besar untuk menjaga stabilitas industri perbankan. Salah satu hal yang sangat penting adalah memastikan setiap bank berada dalam kondisi sehat, serta bisa mendeteksi lebih awal jika ada potensi kebangkrutan.

Masalahnya, ada banyak sekali indikator keuangan yang harus dipantau, dan sulit dilakukan secara manual satu per satu. Karena itu, pendekatan berbasis machine learning bisa sangat membantu. Dengan memanfaatkan data historis, model prediktif ini bisa memperkirakan apakah sebuah bank berpotensi bangkrut atau tidak.

Tujuan utama dari proyek ini adalah:

- Membuat model prediktif untuk memperkirakan potensi kebangkrutan bank.
- Mengetahui indikator keuangan apa saja yang paling berpengaruh terhadap kesehatan bank.

Dengan adanya model ini, Bank Sentral diharapkan bisa mengambil langkah pencegahan lebih cepat, dan membuat kebijakan yang berbasis data.

Data Understanding

Dataset yang digunakan berisi **6.819** baris dan **96** kolom yang mewakili berbagai indikator keuangan bank.

Kolom targetnya adalah '**Bankrupt?**', dengan nilai:

- 0 berarti bank masih beroperasi (tidak bangkrut)
- 1 berarti bank sudah bangkrut

Proporsi datanya cukup timpang yaitu sekitar **96,7%** bank tidak bangkrut, dan hanya **3,3%** yang bangkrut. Artinya, kita berhadapan dengan data yang tidak seimbang (imbalanced dataset).

Semua kolom berisi data numerik, tanpa nilai kosong, jadi tidak perlu proses imputasi. Beberapa contoh kolom penting di antaranya:

- ROA(A) before interest and % after tax
- Operating Gross Margin
- Debt ratio %
- Net Value Per Share (A)
- Cash Flow to Total Assets

Dari sini, bisa dilihat bahwa dataset ini banyak berhubungan dengan rasio profitabilitas, arus kas, dan struktur modal bank.

Data Preparation

Langkah pertama adalah memisahkan data menjadi fitur (X) dan target (y), lalu dibagi menjadi **80%** data train dan **20%** data test.

Karena datanya tidak seimbang, kita menggunakan SMOTE (Synthetic Minority Oversampling Technique) untuk menyeimbangkan kelas minoritas (bank bangkrut).

Setelah proses SMOTE, jumlah data antara kelas 0 dan 1 menjadi seimbang (masing-masing sekitar **50%**).

Kemudian semua fitur dinormalisasi menggunakan StandardScaler agar memiliki skala yang sama, hal ini penting terutama untuk model seperti neural network.

Setelah semua tahap ini, data sudah siap digunakan untuk membangun model prediksi.

Modelling

Dalam analisis ini, tiga algoritma yang digunakan adalah:

1. *Decision Tree*
2. *Random Forest*
3. *Artificial Neural Network (ANN)*

Ketiganya diuji pada data test setelah dilatih di data train. Hasil evaluasi menunjukkan bahwa model *Random Forest* memberikan performa paling baik.

Evaluation

Beberapa metrik yang digunakan untuk menilai model antara lain *Precision*, *Recall*, *F1-score*, dan *ROC-AUC*.

Berikut hasil rata-ratanya

Model	Precision	Recall	F1-score	ROC-AUC
Decision Tree	0.17	0.66	0.27	0.78
Random Forest	0.40	0.61	0.49	0.79
ANN (MLP)	0.35	0.41	0.38	0.69

Dari tabel di atas, bisa dilihat kalau **Random Forest** punya *F1-score* dan *ROC-AUC* tertinggi.

Meskipun *precision*-nya belum terlalu tinggi, model ini punya *recall* yang lumayan bagus (sekitar 0.61), artinya model cukup baik dalam mendeteksi bank yang benar-benar bangkrut.

Feature Importance

Dari hasil analisis *feature importance* pada model *Random Forest*, 5 variabel teratas yang paling memengaruhi kemungkinan bank bangkrut adalah:

- *Net Value Per Share (A)*
- *ROA(C) before interest and depreciation before interest*
- *Operating Gross Margin*
- *Debt ratio %*
- *Cash Flow to Total Assets*

Kelima indikator ini mencerminkan profitabilitas, efisiensi, dan struktur modal bank. Misalnya:

- Bank dengan *ROA* rendah atau margin operasi kecil cenderung punya performa buruk.
- *Debt ratio* tinggi bisa jadi tanda bank terlalu bergantung pada pinjaman.
- *Cash flow* yang rendah menandakan kemampuan bank untuk menutup kewajiban jangka pendek juga rendah.